

HLPO 原生推理性能基准测试报告 (Native Inference Benchmark Report)

1. 测试概览 (Overview)

本测试旨在验证 HLPO (HMF-Laplace-Pomegranate-Ouroboros) 架构在原生推理模式下的性能增益。我们使用了 Run #2 (Aggressive Sparsity) 训练出的模型，并在 Apple M2 Ultra (MPS) 平台上对比了“标准推理”与“原生物理推理”的性能差异。

测试环境

- 设备: Apple M2 Ultra
- 加速: MPS (Metal Performance Shaders) / FP32
- 模型: HLPO GPT-2 Mini (Run #2 Checkpoint)
- 数据: WikiText-2 Test Set (使用训练时的自定义词表, Vocab Size: 33277)

2. 测试方案 (Methodology)

对比配置

1. Baseline (Training Only Mode):

- 模型加载 Run #2 稀疏权重。
- `inference_mode = False`。
- 完整执行所有层 (Laplace + Gravity + Kinetic + FFN)，模拟普通 Transformer 的计算路径。
- 注: 此时模型虽然权重稀疏，但计算图是密集的。

2. Native (Mass Gating Mode):

- 模型加载 Run #2 稀疏权重。
- `inference_mode = True`。
- 物理跳过 (Physics Skipping): 当感知到 Token 的质量 (m) 低于阈值 (10.0) 时，自动跳过 Gravity (拓扑构建) 和 Kinetic (注意力挤压) 计算，仅保留残差传播和必要的 FFN。
- 注: 这是 HLPO 所谓的“暗物质穿透”模式。

3. 测试结果 (Results)

Metric (指标)	Baseline (普通模式)	Native (原生模式)	Delta (变化)
TPS (Tokens/Sec)	25,560	134,435	+426% (5.26x Speedup)
PPL (Perplexity)	1,031.57	1,406.90	+36.3% (Quality Drop)
Active Rate	100%	~0.4%	-99.6% (Sparsity)

关键发现 (Key Findings)

- 极速爆发 (Massive Speedup):** 开启原生推理模式后, 吞吐量提升了 **5.26倍**。这证实了 HLPO 的“质量门控 (Mass Gating)”机制在软件层面也能带来巨大的性能红利, 甚至超越了普通的稀疏矩阵加速比。
- 精度权衡 (Quality Trade-off):** PPL 从 1031 上升到 1406。考虑到 Run #2 的训练 PPL 约为 1236, 原生推理的 PPL 略高于训练水平, 但仍在可接受范围内。这表明模型成功学会了在低质量区域“偷懒”, 但这部分被跳过的计算确实包含少量信息。
- HPU模拟验证:** 该测试验证了 HPU (Holographic Processing Unit) 的设计逻辑。如果在硬件层面实现 Logic Gating, 配合 Power Gating (之前验证的 >99% 动态功耗节省), HLPO 芯片将具有极高的能效比。

4. 结论与建议 (Conclusion)

HLPO Run #2 模型配合原生推理算法, 实现了 “**5倍速度, 1.3倍PPL**” 的交换。

- 对于即时性要求极高的场景 (Real-time Edge AI): 5.26x 的加速是决定性的, PPL 的损失完全可以接受。
- 对于精度要求高的场景: 可以适当降低 `gravity.threshold` (如从 10.0 降至 5.0), 在速度和精度之间找到更优的平衡点。

Next Step:

- 进一步微调阈值, 寻找帕累托最优前沿 (Pareto Frontier)。
- 将 Python 侧的跳过逻辑下沉到 Rust (hlpo_core) 或 CUDA Kernel 中以获得更极致的性能。